

Table des matières


1. L'entreprise.....	1
1.1. Contexte.....	1
1.2. Environnement technologique de l'entreprise.....	1
2. Organisation du projet.....	4
3. Description du projet et des missions	4
4. Conclusion (Dernière semaine)	10

1. L'entreprise

1.1. Contexte

J'ai effectué mon stage de première année, du 26/05/2026 au 26/06/2025 à Paris Match. Paris Match est un journal hebdomadaire créée en 1949 avec sa devise culte « le poids des mots, le choc des photos ». Le journal est actuellement dans le groupe de luxe LVMH (Moët Hennessy Louis Vuitton). Elle est l'entreprise numéro 1 sur son marché.

J'ai été affecté au service de la Doc-Texte, c'est ici qu'on gère les PDF et les XML que je traite.




1.2. Environnement technologique de l'entreprise

Logiciel :

- Teams / Outlook : Afin de pouvoir communiquer dans l'entreprise. Teams permet également de pouvoir organiser des réunions.


- Deskare : Logiciel permettant de gérer la réservation de bureau sur place. L'entreprise fonctionnant sur un système de « flex-office ». L'outil permet également de gérer les absences et jours en télétravail.
- Jira : Ils utilisent également l'outil Jira pour gérer leurs différents projets. Jira permet de gérer les différentes missions et choses à faire sous la forme de tickets. C'est un format ressemblant à Trello.



Sécurité :

- MAIA : Couche de sécurité sur les IA.
- OKTA : Système d'authentification pour l'ordinateur.

Matériel de l'entreprise :



Baie de brassage de l'entreprise au niveau 6. Les câbles rouges et bleus permettent le découpage entre les 2 réseaux de l'entreprise. L'un (câbles rouges), étant pour l'ancien réseau de l'entreprise, en effet certains postes sont encore sous le réseau d'avant rachat de l'entreprise par LVMH, les câbles bleus correspondent aux postes qui fonctionnent sous le nouveau réseau de l'entreprise.



Imprimante spéciale à la fabrication du journal. Celle-ci permet d'imprimer des échantillons du journal pour que les personnes au service de la fabrication puissent se rendre compte des couleurs sorties. Cela permet également d'avoir un bon à tirer pour les imprimeurs.



Serveur fairy d'impression, il permet de créer une file d'attente sur les imprimantes. Toutes les imprimantes en possèdent un.


GettyTransform est un outil développé en Python dans le cadre d'un besoin interne exprimé par Thierry, responsable du projet. Il s'adresse à Yasmina, utilisatrice finale non-technique, et a pour objectif d'automatiser un traitement de transformation sur des fichiers texte tabulés exportés depuis la plateforme Getty Images.

Concrètement, l'outil permet à l'utilisateur de sélectionner un fichier d'export Getty (.txt) directement depuis son poste, de le valider structurellement (vérification des colonnes et du séparateur), puis d'appliquer une série de transformations automatisées : suppression des lignes à royaltys nulles, recalcul des royaltys pour les ventes américaines, normalisation des références d'assets, et uniformisation des séparateurs décimaux. En sortie, deux fichiers sont générés automatiquement : un fichier TXT tabulé et un fichier Excel, tous deux horodatés.

Les deux principales contraintes du projet étaient de proposer une interface simple et accessible à un utilisateur non-technique, et de permettre une installation sans droits administrateur sur le poste de travail.

L'environnement technologique pour ce projet était d'utiliser *Python* comme langage, avec la librairie *Pandas* (permettant de générer une interface graphique simple d'utilisation) et *Openpyxl* (permettant de générer un fichier Excel en sortie).


Voici une utilisation imagée de l'outil.




Voici l'interface principale de l'outil. Après avoir cliqué sur « parcourir » cette fenêtre s'ouvre, nous demandant de choisir notre fichier texte tabulé.

Name	Contact ID	Contract ID	Contract Name	Royalty Month	Invoice Number	Sales Date	Collection	Sale Region	Product Type
Notes	File Size	Agent	Customer Name	Credit Line	Asset Number	Alternate Asset	Number	Asset Description	Rights: Industry
Rights Usage	Rights: Use Territory/Duration	Sales Territory	Percent of Product	Purchase from Site	License Fee in USD	Royalty			
Rate	Gross Royalty in USD	Royalty Pay Date	Contributors Net payment (summary for full stmt)	Currency					
	StatementSummary_CarryForwardNegativeEarnings	StatementSummary_NewAdvance	StatementSummary_OpeningBalance	StatementSummary_US_ContributorsShare					
	StatementSummary_US_Deductions	StatementSummary_US_Gross	StatementSummary_US_MinimumNotMetCarriedForward	StatementSummary_US_Net					
	StatementSummary_US_NetPayment	StatementSummary_US_NetPaymentInCurrency	StatementSummary_US_PaymentCarriedForward						
	StatementSummary_US_EstimatedTaxOnAmount	StatementSummary_US_EstimatedTaxOnAmountInCurrency	StatementSummary_NonUS_ContributorsShare						
	StatementSummary_NonUS_Deductions	StatementSummary_NonUS_Gross	StatementSummary_NonUS_MinimumNotMetCarriedForward						
	StatementSummary_NonUS_NetEarnings	StatementSummary_NonUS_Net	StatementSummary_NonUS_NetPaymentInCurrency						
	StatementSummary_NonUS_PaymentCarriedForward	StatementSummary_NonUS_EstimatedTaxOnAmount							
	StatementSummary_NonUS_EstimatedTaxOnAmountInCurrency	StatementSummary_Totals_ClosingBalance	StatementSummary_Totals_Deductions						
	StatementSummary_Totals_Gross	StatementSummary_Totals_MinimumNotMetCarriedForward	StatementSummary_Totals_NetEarnings						
	StatementSummary_Totals_NetPayment	StatementSummary_Totals_PaymentCarriedForward	StatementSummary_Totals_EstimatedTaxOnAmount						
	StatementSummary_Totals_EstimatedTaxOnAmountInCurrency								
Paris Match	896618	5068674	5068674;G IP;Philippe Petit/Paris Match avr.-2026						
	USD	0.000000000	0.000000000	100.000000000	100.000000000	0.000000000	0.000000000	0.000000000	0.000000000
	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000
	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000
	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000	0.000000000
Paris Match	896618	5159903	5159903;G IP;MICKE Sebastien avr.-2026	DD-1000142265634	01-avr.-2026	Paris Match Archive	US SALES		
	Premium Access Time Limited	Bloomberg LP Group	Paris Match via Getty Images						
	160688832-(Premium Pricing - DOUBLE RATES APPLY) NEW YORK, S	2026 Mar 01 - 2027 Feb 28. Publishing: Print & Online. World. Editorial -							
	Website(s);Editorial - Social Media Platforms;Editorial - Re-Display Rights: In-Context Syndication;Editorial - Re-Display Rights: In-Context Promotional								
	Use;Editorial - Print Publication(s) (Interior use only);Editorial - Other;Editorial - Mobile/Tablet Applications;Editorial - Film/TV Programs;Editorial -								
	Digital Distribution Platforms. editorial use in all licensee media, WW distribution, in perp. Digital. One use per download. In perpetuity, within the								
	context of the original use. PERP REPRO RIGHTS FOR RF. NEW YORK	1.000000000	Getty	22.900000000	0.500000000	11.450000000			
	2026-05-25T00:00:00	673.951740000	USD	0.000000000	0.000000000	100.000000000	100.000000000	0.000000000	0.000000000

Extrait d'un fichier texte tabulé



Nous cliquons ensuite sur « ouvrir », ce qui importera le fichier. Puis nous appuyons ensuite sur « Lancer le traitement ».



Un sous répertoire se créera et enregistrera le fichier texte pour pouvoir l'envoyer sur Getty, et un fichier Excel pour que l'utilisateur puisse consulter les changements lui-même.

	ExportGetty_final_20260612-104451.txt		12/06/2026 10:44	Document texte	73 Ko
	ExportGetty_final_20260612-104451.xlsx		12/06/2026 10:44	Feuille de calcul Micr...	42 Ko

Traitement de XML défectueux pour Elle

Le magazine « Elle » était avant dans le même groupe que Paris Match (*Lagardère*). Il y a donc certaines choses qui sont encore sous traitées chez Paris Match. Les magazines de chez Elle sont organisés sous la forme de fichier zip, contenant ensuite des fichiers XML par article présent dans le magazines. Dans ce cas-ci, certains XML avait une balise vide. Une balise qui était « onCoverDate » qui correspondait à la date sur la couverture du magazine. Sauf que la balise étant vide vide, le fichier zip des XML ne pouvait pas être mis sur le serveur

La date qui est renseigné (OnCoverDate), est la même qu'une date qui est dans une autre balise qui est-elle, renseigné (PublicationDate). De plus, les deux dates sont au même format (AAAA-MM-JJ). J'ai donc réalisé un script python qui renseigne automatiquement la balise « OnCoverDate », à l'aide de la balise « PublicationDate ». Voici également un extrait d'un fichier XML avant traitement, avec en surligner la balise renseignée, et en dessous la balise vide.

```
<eddf:EddfDocument xmlns:eddf="http://ressources.edd.fr/xml/EddfDocument">
  <eddf:documentMeta xmlns:emd="http://ressources.edd.fr/xml/EddMetadata" xmlns:emd:publicationdate>2026-04-02</emd:publicationdate>
  <emd:publicationdate>2026-04-02</emd:publicationdate>
  <emd:title>Cover page</emd:title>
  <emd:language>fr-FR</emd:language>
  <emd:onCoverDate/>
  <emd:publisher code="HFEL">ELLE</emd:publisher>
  <emd:type>cover</emd:type>
  <emd:rights>2026 ELLE</emd:rights>
  <emd:issueNumber>4189</emd:issueNumber>
  <emd:pageNumber>0001</emd:pageNumber>
  <emd:wordCount>65</emd:wordCount>
  <emd:characterCount>309</emd:characterCount>
  <emd:seal>04fAz1h5F6ne1GU0g7E30As3ZF88Y59Zy1wS48wXy_3Jporo4h2wcDu8VMgubBc240h
```

```

1 import re
2 import os
3
4
5 DOSSIER_SOURCE = "sources" #Permet de gérer Les répertoires d'entrées et de sortie
6 DOSSIER_OUTPUT = "output"
7
8
9
10 os.makedirs(DOSSIER_OUTPUT, exist_ok=True) #Créer le dossier de sortie si il n'existe pas
11
12 for nom_fichier in os.listdir(DOSSIER_SOURCE): #Lit tout Les fichiers avec L'extension XML
13
14     if not nom_fichier.endswith(".xml"):
15         continue
16
17     chemin_source = os.path.join(DOSSIER_SOURCE, nom_fichier)
18     chemin_output = os.path.join(DOSSIER_OUTPUT, nom_fichier)
19
20     with open(chemin_source, 'r', encoding='utf-8') as f:
21         contenu = f.read()
22
23     match_date = re.search(r'<emd:publicationdate>([\d\~]+)</emd:publicationdate>', contenu) #Cherche si la balise est renseigné
24
25     if not match_date:
26         print(f"{nom_fichier} : aucune date trouvée dans <emd:publicationdate>") #Génère une erreur si aucune date n'est trouvé dans la balise
27         continue
28
29     date = match_date.group(1)
30
31     if '<emd:onCoverDate>' not in contenu:
32         print(f"{nom_fichier} : déjà corrigé, aucune action effectuée") #Si la balise est déjà renseigné ne rien faire
33         continue
34
35     contenu_corrige = contenu.replace(
36         '<emd:onCoverDate>',
37         f'<emd:onCoverDate>{date}</emd:onCoverDate>'
38     ) #Remplace la balise, par la balise rempli
39
40     with open(chemin_output, 'w', encoding='utf-8') as f:
41         f.write(contenu_corrige)
42
43     print(f"{nom_fichier} : corrigé avec <emd:onCoverDate>{date}</emd:onCoverDate>")
44

```

Voici le code source du script python et voici une capture d'écran d'un traitement réalisé sur un échantillon.

```

PS C:\Users\rboucourt\OneDrive - Les Echos Le Parisien\Documents\Traitement XML Elle> python traitement_multiple.py
article_0001_924e63944918d47a369bfa0533870bfc2c0ccf2a (1).xml : déjà corrigé, aucune action effectuée
article_0001_924e63944918d47a369bfa0533870bfc2c0ccf2a (2).xml : corrigé avec <emd:onCoverDate>2026-04-16</emd:onCoverDate>
article_0001_924e63944918d47a369bfa0533870bfc2c0ccf2a (3).xml : corrigé avec <emd:onCoverDate>2026-04-23</emd:onCoverDate>
article_0001_924e63944918d47a369bfa0533870bfc2c0ccf2a.xml : corrigé avec <emd:onCoverDate>2026-04-02</emd:onCoverDate>
PS C:\Users\rboucourt\OneDrive - Les Echos Le Parisien\Documents\Traitement XML Elle>

```

Projet de régénération des fichiers de la BNF

La BNF (Bibliothèque Nationale de France) a scanné des archives de Paris-Match, pour en générer des fichiers PDF et des fichiers XML (à l'aide de 1 fichier XML par article). Cependant le travail de la BNF a été loupé, car l'OCR (la capacité à reconnaître du texte sur une image) des PDF a mal fonctionné. Le texte avait donc beaucoup d'erreurs. Le but de ce projet, était donc de régénérer des fichiers XML, avec de l'IA pour générer le texte, à partir des PDF défectueux de la BNF.

Pour développer mon traitement, j'ai dû développer dans un environnement de développement de Google (Colab). Colab permet de séparer les éléments du code en plusieurs blocs, ce qui est pratique pour le débogage car je peux exécuter facilement une partie du code sans tout exécuter.

Celui-ci me permet de développer directement dans le cloud de google, ce qui permet l'ajout de la fonctionnalité de Vertex Ai. Le langage de programmation utilisé pour mon outil est le python, c'est un langage qui est pratique à utiliser pour faire des appels à des API de IA, mais c'est également le langage présent sur Google Colab.

Ceci me permet facilement une intégration de modèle IA dans mon traitement, avec beaucoup de facilité, et surtout, je peux changer facilement de modèle en cours de développement.

Le but de l'outil actuel est de pouvoir mettre un répertoire de magazine sur le cloud, contenant, des fichiers PDF et XML défectueux. Ensuite l'IA liera les fichiers, et à l'aide d'un prompt, corrigera et mettra au nouveau format les XML pour les nouvelles conventions.

Voici une liste d'erreurs que j'ai pu rencontrer :

- ✅ Fichier créé : gs://poc-pdf-bnf-vertex/output/xml/2026-06-22/1/H_PAMA_19560728_00381_N_018_021N.xml
- ⚠ Impossible de parser l'article 5 : mismatched tag: line 64, column 238
- ✅ Fichier créé : gs://poc-pdf-bnf-vertex/output/xml/2026-06-22/1/H_PAMA_ERREUR_2026-06-22_08-18-58_005.xml

Cette erreur a été générée parce qu'un fichier XML avait une balise en trop, qui de plus n'était pas fermée.

```
son cœur était resté da  
que. »</text>  
près du lac de Balaton.  
des « malgré eux » et se
```

En effet cette balise n'est pas censée être générée, ce qui provoque une erreur dans le découpage des différents fichiers XML. Pour la corriger, j'ai ajouté une fonction qui me permet de récupérer l'erreur et de remplacer la mauvaise balise par une bonne balise. Voici par exemple la fonction qui me permet de gérer ce cas d'erreur là :

```
def CORR_ERR_02(article: str, index: int) -> tuple[str, int]:  
    """  
    CORR-ERR-02 : Corrige les balises inattendues.  
    Exemple : </text> → </P>, <para> → <P>  
    """  
    corrections = []  
  
    replacements = {  
        r'</text>' : '</P>',  
        r'<text>' : '<P>',  
        r'</para>' : '</P>',  
        r'<para>' : '<P>',  
    }  
  
    for pattern, replacement in replacements.items():  
        occurrences = re.findall(pattern, article, flags=re.IGNORECASE)  
        if occurrences:  
            for occ in occurrences:  
                corrections.append(f"Balise inattendue '{occ}' → '{replacement}'")  
            article = re.sub(pattern, replacement, article, flags=re.IGNORECASE)  
  
    if corrections:  
        logger.warning(  
            f"\n{'-'*60}\n"  
            f"  ✎ [CORR-ERR-02] | Article n°{index}\n"  
            + "\n".join(f"  • {c}" for c in corrections) + "\n"  
            f"{'-'*60}\n"  
        )  
  
    return article, len(corrections)
```

Également, j'ai eu une erreur. Lorsque je générerais mes fichiers, à cause de la convention de nommage de mes fichiers, j'avais une erreur qui faisait que des fichiers avaient le même nom. J'ai donc décidé d'ajouter un suffixe à mes fichiers.

```
# — ERR-01 : Gestion des doublons —————
if nom_sans_ext in noms_utilises:
    noms_utilises[nom_sans_ext] += 1
    nom_fichier_base = f"{nom_sans_ext}_{noms_utilises[nom_sans_ext]:02d}.xml"
    logger.warning(
        f"[ERR-01] Doublet détecté sur '{nom_sans_ext}' "
        f"→ renommé en '{nom_fichier_base}'"
    )
else:
    noms_utilises[nom_sans_ext] = 1
    nom_fichier_base = f"{nom_sans_ext}.xml"
```

Une autre erreur était la balise Auteur. En effet la balise auteur dans la convention de la pqhn était au format « vrac », un format où tous les auteurs étaient mis dans la même balise, séparé par un point-virgule. Cependant, j'ai eu une erreur car quelquefois l'ia la générait au format « pn », ce qui créait une balise où les auteurs étaient mis chacun dans une balise différente, j'ai donc créé un script qui corrige cette erreur. Et j'ai enregistré cette erreur.

```
↳ [CORR-ERR-06] | Article n°1
• type="PN" → type="VRAC"
```

```
[2026-06-24 13:18:49] [WARNING]
```

```
def CORR_ERR_06(article: str, index: int) -> tuple[str, int]:
    """
    CORR-ERR-06 : Corrige le type d'auteur incorrect et fusionne les balises <AUTEUR> multiples.
    Exemple : type="PN" → type="VRAC" + fusion des <AUTEUR> en un seul séparé par ';' ;
    """
    corrections = []

    # — Correction du type="PN" → type="VRAC" —————
    if 'type="PN"' in article:
        article = article.replace('type="PN"', 'type="VRAC"')
        corrections.append('type="PN" + ' + ' → ' + 'type="VRAC"')

    # — Fusion des balises <AUTEUR> multiples —————
    auteurs = re.findall(r'<AUTEUR>(.+?)</AUTEUR>', article, flags=re.DOTALL)
    if len(auteurs) > 1:
        auteurs_fusionnes = " ; ".join(a.strip() for a in auteurs)
        article = re.sub(r'<AUTEUR>.+?</AUTEUR>', '', article, flags=re.DOTALL)
        article = re.sub(
            r'(<AUTEURS[^\>]*>)',
            f'\\1\\n <AUTEUR>{auteurs_fusionnes}</AUTEUR>',
            article
        )
        corrections.append(f'{len(auteurs)} balises <AUTEUR> fusionnées → '{auteurs_fusionnes}''')

    if corrections:
        logger.warning(
            f"\\n{'-'*60}\\n"
            f"↳ [CORR-ERR-06] | Article n°{index}\\n"
            f"+ '\\n'.join(f' • {c}' for c in corrections) + '\\n"
            f"{'-'*60}"
        )

    return article, len(corrections)
```

4. Conclusion (Dernière semaine)

Ma conclusion est que je pense que ce stage a été très intéressant. J'ai pu aider sur plusieurs projets, tout en étant en autonomie sur mon projet principal. Et cela m'a permis de mieux apprendre à utiliser l'IA.

Et sur un point de vue de culture général, ce stage m'a permis d'en apprendre un peu plus sur le monde du journalisme.

Signature du rapport de stage par le tuteur

Philippe PRUDANT – Directeur Produits & Technologies – Paris Match

A handwritten signature in black ink, consisting of a stylized 'P' followed by a horizontal line and a diagonal stroke.